QWEN PRUNING LAB / 可复现实验报告

8GB 单卡上的大模型结构化剪枝

Qwen3-1.7B · 校准评分 × 有限 LoRA × 同预算对照

RTX 4060 Laptop 8GB | 内存 16GB | 单模型驻留 | 完整 BF16 权重

剪后第64步：最终 F1 ↑

83.39

同预算原模型 86.05；差 -2.67pp

剪后第64步：最终 PPL ↓

21.67

同预算原模型 21.02；差 +3.11%

合并后去重参数减少

2.56%

原 1.721B → 剪后 1.677B

01 最终评测：压缩成立，质量仍有代价

200 题 / 16384 个 LM 有效目标 token；四个产物在 final 前冻结，之后不重选。

最终测试产物	EM ↑	F1 ↑	PPL ↓
原模型，未训练	67.50	84.70	22.77
校准剪枝 5888，未训练	63.50	82.71	23.76
原模型 + LoRA 64步，已合并	**67.00**	**86.05**	**21.02**
校准剪枝 + LoRA 64步，已合并	**61.00**	**83.39**	**21.67**

同为64步，剪后比原模型：EM -6pp，F1 -2.67pp，PPL +3.11%。

恢复相对剪后未训练：F1 82.71 → 83.39；PPL 23.76 → 21.67。未追平同预算原模型。

02 方法：真实缩小矩阵，保留同预算恢复对照

校准观察

64 段 × 256 token
平均绝对输出权重 × 激活均方根

结构化剪枝

28 层 MLP：6144 → 5888
gate/up 行与 down 列同步裁剪

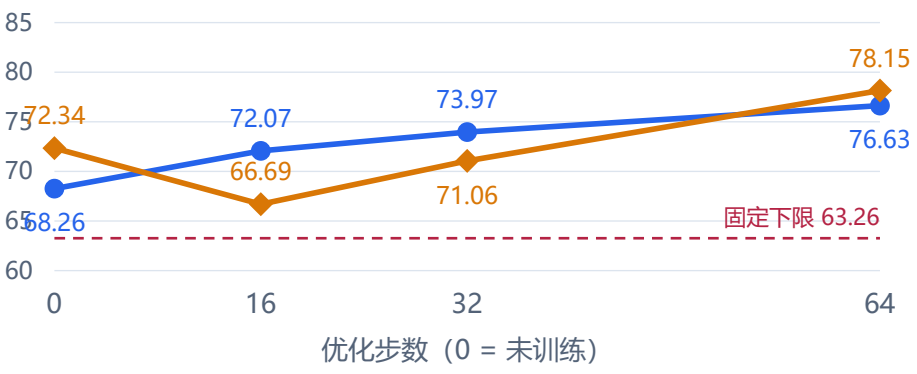
有限 LoRA 恢复

512 条，6762 个监督 token，64步
原 / 剪后同预算；r=8，合并后再评测

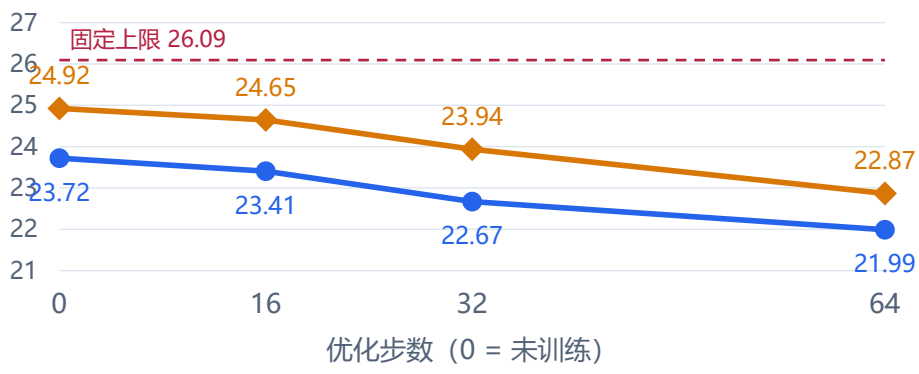
03 验证过程：保留波动，不把验证优势当最终优势

validation（未合并 FP32 LoRA）：100题（99组）/ 8192 LM目标　● 原模型　◆ 校准剪枝 5888

F1 ↑ 越高越好



PPL ↓ 越低越好



虚线为相对原模型step0的固定门槛；validation用于选checkpoint，final不参与调参或再选择。

04 受控资源：两轮独立进程，固定32 token输出

同为64步、已合并：512 token输入时生成峰值分配显存3.4148→3.3328 GiB，少84 MiB（2.40%）。
全组资源对照：两轮未观察到稳定加速，128 token输入部分比较变慢；文件体积差含共享权重去重。

失败保留：联合平方幅值基线5632，validation F1 2.87 / PPL 285.28；不概括所有幅值方法。

工程证据：本地328 项CPU测试通过，文件SHA绑定、训练冻结核查与保存重载验证。

范围：单机、单seed、本地筛选子集；非官方隐藏测试，无显著性检验；助手复核不等于用户验收。

Qwen Pruning Lab　压缩、质量与速度分别报告；一次实验不能证明通用能力或普遍加速。

https://github.com/noyce6983981-max/qwen-pruning-lab